

ԵՂԱՆԱԿԱՅԻՆ ՏՎՅԱԼՆԵՐԻ ՎԻՃԱԿԱԳՐԱԿԱՆ ԵՎ ՄԵՔԵՆԱՅԱԿԱՆ ՈՒՍՈՒՑՄԱՆ ՎԵՐԼՈՒԾՈՒԹՅՈՒՆ

1. Նախաբան և Տվյալների Նախնական Մշակում (Data Preprocessing)

Աշխատանքի նպատակն է ուսումնասիրել եղանակային տարբեր արտաքին գործոնների ազդեցությունը մարդու մարմնի ջերմաստիճանի (ընկալվող ջերմության) վրա: Տվյալների ընտրվել են Kaggle-ից ([Dataset](#)): Նախագծի ամբողջական իրականացումը՝ ներառյալ ծրագրային կոդերը, գրաֆիկական պատկերները և Kaggle հարթակից ներբեռնված սկզբնական տվյալները, հասանելի են GitHub-ի հետևյալ հղումով՝ [Github](#): Վերլուծության հուսալիությունն ապահովելու համար իրականացվել են հետևյալ քայլերը:

Պատահական ընտրանք. Մեծ տվյալների բազայից վերցվել է 500 պատահական դիտարկում (տող) արդյունքների կայունությունն ապահովելու համար (`random_state=2026`):

Ընտրված փոփոխականները կազմում են եղանակային պայմանների հիմնական «ֆիզիկական պրոֆիլը», որը թույլ է տալիս հասկանալ, թե ինչպիսին է իրականում շրջակա միջավայրը և ինչպես է այն ընկալվում մարդու օրգանիզմի կողմից:

Temperature (Օդի իրական ջերմաստիճան) - Սա օդի կինետիկ էներգիայի չափումն է՝ արտահայտված Ցելսիուսով ($^{\circ}\text{C}$): Սա այն ջերմաստիճանն է, որը ցույց է տալիս ջերմաչափը: Հանդիսանում է եղանակային ամենակարևոր ցուցանիշը, որը հիմք է ծառայում մյուս բոլոր հաշվարկների համար:

Humidity (Հարաբերական խոնավություն) - Սա օդի մեջ առկա ջրային գոլորշիների քանակն է՝ արտահայտված տոկոսներով (%): Ցույց է տալիս, թե օդը որքանով է «հագեցած» խոնավությամբ: 100% խոնավության դեպքում օդն այլևս չի կարող ընդունել գոլորշի, ինչը հանգեցնում է մառախուղի կամ տեղումների: Բարձր խոնավությունը դժվարացնում է մարմնից քրտինքի գոլորշիացումը, ինչի պատճառով մարդն իրեն ավելի տաք է զգում, քան իրական ջերմաստիճանն է:

Wind Speed (Քամու արագություն) - Օդային զանգվածների տեղաշարժման արագությունը՝ կմ/ժ-ով (km/h): Ցույց է տալիս, թե որքան արագ է օդը հոսում որոշակի կետի վրայով: Քամին ակտիվացնում է ջերմափոխանակությունը մաշկի և շրջակա օդի միջև: Ցուրտ եղանակին այն մեծացնում է մարմնից ջերմության կորուստը՝ ստիպելով մարմնին ավելի ցուրտ ընկալել ջերմաստիճանը (`wind chill effect`):

Visibility (Տեսանելիություն) - Այն ամառվելագույն հեռավորությունը (կմ-ով), որի վրա հնարավոր է հստակ տարբերել օբյեկտները: Այս ցուցանիշը հիմնականում կախված է մթնոլորտում առկա մասնիկներից (մառախուղ, ծուխ, փոշի, տեղումներ): Ցածր տեսանելիությունը հաճախ վկայում է օդի խոնավության բարձր մակարդակի կամ մթնոլորտային խառնուրդների մասին:

Pressure (Մթնոլորտային ճնշում) - Օդի սյան կողմից մակերեսի վրա գործադրվող ճնշումը՝ միլիբարներով (millibars): Ճնշման փոփոխությունները ցույց են տալիս մթնոլորտային ճակատների տեղաշարժը: Ցածր ճնշումը սովորաբար կապված է ամպամածության և տեղումների, իսկ բարձր ճնշումը՝ պարզ, արևոտ եղանակի հետ: **Apparent**

Temperature (Մարմնի ընկալվող ջերմաստիճան) - Սա այն ջերմաստիճանն է, որն իրականում «զգում» է մարդու մարմինը՝ հաշվի առնելով ջերմաստիճանը, խոնավությունը և քամին: Սա ոչ թե գործիքային չափում է, այլ հոգեֆիզիոլոգիական ցուցանիշ: Տաք եղանակին՝ բարձր խոնավությունը բարձրացնում է մարմնի ընկալվող ջերմաստիճանը: Ցուրտ եղանակին՝ քամու արագությունը իջեցնում է այն:


Տիպերի փոխարկում. Բոլոր հիմնական սյուները (Temperature, Humidity, Wind Speed, Visibility, Pressure) փոխարկվել են թվային (float) ձևաչափի:

Բացակայող արժեքների հեռացում. Ոչ թվային կամ բացակայող (NaN) արժեքներ պարունակող տողերը մաքրվել են, ինչի արդյունքում ստացվել է վերլուծության համար պատրաստի մաքուր տվյալների բազա:

	Temperature (C)	Humidity	Wind Speed (km/h)	Visibility (km)	Pressure (millibars)	Apparent Temperature (C)
0	8.244444	0.85	0.0000	15.8263	1017.33	8.244444
1	10.116667	0.49	7.6636	11.2056	1015.39	10.116667
2	23.122222	0.80	2.9302	14.1680	1016.53	23.122222
3	7.755556	0.54	7.6475	9.9820	1028.23	6.466667
4	12.733333	0.70	10.5938	9.9015	1020.08	12.733333

2. Չույգային Կորելացիաների Վերլուծություն (Pairplot Analysis)

Տվյալների փոխադարձ կապերը տեսողականորեն գնահատելու համար կառուցվել է չույգային գրաֆիկների մատրիցը (Pairplot): Պատկերը տեսնելու համար սեղմեք այստեղ



Հիմնական եզրակացություններ.


Ուժեղ գծային կապ. Ինչպես և սպասվում էր, օդի իրական ջերմաստիճանի (Temperature) և մարմնի ջերմաստիճանի (Apparent Temperature) միջև առկա է գրեթե կատարյալ դրական գծային կապ:

Հակադարձ կապ. Օդի ջերմաստիճանի և խոնավության (Humidity) միջև նկատվում է բացասական միտում՝ ավելի բարձր ջերմաստիճաններին հաճախ ուղեկցում է ցածր խոնավություն:

Թույլ կապեր. Մթնոլորտային ճնշումը (Pressure) և քամու արագությունը (Wind Speed) ցուցաբերում են ավելի ցրված պատկեր, ինչը հուշում է ոչ գծային կամ ավելի թույլ կապերի մասին:

3. Տվյալների Նորմալության Ստուգում (Shapiro-Wilk Test & Q-Q Plots)

Մոդելավորումից առաջ յուրաքանչյուր փոփոխականի համար իրականացվել է **Shapiro-Wilk** վիճակագրական թեստը և գծվել են **Q-Q Plot** գրաֆիկները: Եթե $p\text{-value} > 0.05$, ընդունվում է տվյալների նորմալության վարկածը: Մեր բոլոր փոփոխականների դեպքում $p\text{-value}$ -ն ստացվել է փոքր 0.05-ից ($p < 0.001$), ինչը նշանակում է՝ **տվյալները չեն հետևում կատարյալ նորմալ բաշխմանը**: Գրաֆիկների վրա կետերի շեղումը ուղիղ գծից (հատկապես ծայրամասերում) հաստատում է Shapiro-Wilk թեստի արդյունքը: Թեև Shapiro-Wilk թեստի W վիճակագրությունը մոտ է 1-ին (օրինակ՝ Temperature-ի դեպքում 0.9866), $p\text{-value}$ -ն ցույց է տալիս նորմալության վարկածի մերժում: Սա պայմանավորված է թեստի բարձր զգայունությամբ ընտրանքի մեծ ծավալի պայմաններում: Այնուամենայնիվ, Q-Q Plot-ը ցույց է տալիս, որ տվյալների մեծ մասը գտնվում է տեսական նորմալ բաշխման ուղիղ գծի վրա, ինչը թույլ է տալիս կիրառել պարամետրիկ մեթոդներ (ինչպիսիք են ռեգրեսիան)՝ հաշվի առնելով որոշակի շեղումների առկայությունը: Ավելի մանրամասն տեղեկատվության համար խնդրում եմ նայել Հավելվածը:



4. Դասական Գծային Ռեգրեսիա (OLS Regression)

Կառուցվել է բազմաչափ գծային ռեգրեսիայի մոդել (Ordinary Least Squares):

OLS Regression Results						
Dep. Variable:	Apparent Temperature (C)	R-squared:	0.991			
Model:	OLS	Adj. R-squared:	0.991			
Method:	Least Squares	F-statistic:	5.086e+04			
Date:	Tue, 02 Nov 2020	Prob (F-statistic):	0.00			
Time:	01:42:21	Log likelihood:	-151.48			
No. Observations:	360	AIC:	304.97			
Df Residuals:	357	BIC:	306.00			
Df Model:	3					
Covariance Type:	opgls					
	coef	std err	t	P> t	[0.025	0.975]
Intercept	-2.1224	0.538	-3.931	0.000	-3.228	-1.117
temperature (C)	1.1393	0.007	159.807	0.000	1.125	1.153
humidity (%)	0.7954	0.137	5.811	0.001	0.521	1.069
wind speed (m/s)	-0.0075	0.007	-1.085	0.280	-0.102	0.087
visibility (km)	-0.0021	0.003	-0.515	0.606	-0.007	0.004
pressure (hPa)	-0.0003	0.000	-0.791	0.431	-0.001	0.001
sqrt(humidity)	0.0022	0.000	3.682	0.000	0.001	0.003
sqrt(visibility)	0.1176	0.003	39.120	0.000	0.112	0.122
Kurtosis:	0.3425	0.000	3.425	0.001	0.340	0.345
Skewness:	0.0282	0.000	2.820	0.006	0.026	0.030

Notes:
[1] Standard errors assume that the covariance matrix of the errors is correctly specified.
[2] The condition number is large, 1.3e+04. This might indicate that there are strong multicollinearity or other numerical problems.

Արդյունքների մեկնաբանություն.


Մոդելի որակը (R^2). R^2 (Դետերմինացիայի գործակիցը) ստացվել է բավականին բարձր ($R^2 = 0.991$), ինչը նշանակում է, որ մեր ընտրած գործոնները 99% ճշգրտությամբ բացատրում են մարմնի ջերմաստիճանի փոփոխությունը: Ինչպես նաև կարող ենք տեսնել որ Adjusted R^2 նույնպես բավական բարձր է՝ Adjusted $R^2 = 0.991$, ինչից կարող ենք եզրակացնել, որ փոփոխականները որոնք ավելացվել են գույտ քանակի համար չեն ավելացվել, այլ նրանք բավական լավ բացատրում են բացատրվող փոփոխականը:

Գործակիցների վերլուծություն. **Temperature (C)** ($\text{coef} = 1.1393$, $p = 0.000$)՝ մյուս բոլոր գործոնները հաստատում են պահելու դեպքում, օդի իրական ջերմաստիճանի ամեն 1°C -ով բարձրացումը հանգեցնում է նրան, որ մարմինն այն ընկալում է միջինում 1.14°C -ով ավելի տաք: Խիստ վիճակագրորեն նշանակալի է ($p < 0.001$): **Humidity** ($\text{coef} = 0.7954$, $p = 0.015$)՝ Խոնավության ցուցանիշի 1 միավորով աճը հանգեցնում է մարմնի ջերմաստիճանի մոտ 0.8 աստիճանով բարձրացման: Ֆիզիկապես սա բացատրվում է նրանով, որ բարձր խոնավության պայմաններում մաշկից քրտինքի գոլորշիացումը դանդաղում է, և մարմինն իրեն ավելի շոգ է զգում: Վիճակագրորեն նշանակալի է 5% նշանակալիության մակարդակում դեպքում ($p =$


0.015 < 0.05): **Wind Speed (km/h) (coef = -0.0871, p = 0.000)**՝ Քամու արագության ամեն 1 կմ/ժ-ով ուժեղացումը իջեցնում է ընկալվող ջերմաստիճանը մոտ 0.09°C-ով (կամ ~1°C անկում՝ քամու ամեն 11-12 կմ/ժ արագացման դեպքում): Սա դասական քամու սառեցնող էֆեկտն է: Խիստ վիճակագրորեն նշանակալի է ($p < 0.001$): **Visibility (km) & Pressure (millibars)**՝ Տեսանելիության p-value-ն հավասար է **0.908**, իսկ ճնշմանը՝ **0.484**: Քանի որ այս երկու արժեքները գերազանցում են 0.05 սահմանը, դա նշանակում է, որ այս երկու փոփոխականները **վիճակագրորեն նշանակալի ազդեցություն չունեն** մարմնի ջերմաստիճանի ընկալման վրա: Գործնականում մոդելի համար նրանց գործակիցները համարժեք են զրոյի: **const (Հաստատուն) (coef = -2.1224, p = 0.000)**՝ սա ռեգրեսիոն հավասարման ազատ անդամն է: Մաթեմատիկորեն այն ցույց է տալիս, որ եթե բոլոր նախորդ 5 գործոնների արժեքները հավասար լինեն 0-ի, ապա մարմնի ընկալվող ջերմաստիճանը կլինի -2.12°C: Քանի որ Visibility & Pressure փոփոխականները պարզվեց, որ նշանակալի չեն, աղմուկը նվազեցնելու նպատակով նպատակահարմար է այդ երկու գործոնները հեռացնել հաջորդիվ կառուցվող մոդելներից՝ կենտրոնանալով միայն Temperature, Humidity & Wind Speed եռյակի վրա: Հետագայում մոդելը բարելավվելու նպատակով կարելի է նման ռեգրեսիա իրականացնել:

5. Հիմնական Բաղադրիչների Վերլուծություն (PCA)

PC1՝ Առաջին գլխավոր բաղադրիչը պարունակում է տվյալների ընդհանուր վարիացիայի (ինֆորմացիայի) մոտ 41.0%-ը: **PC2՝ Երկրորդ գլխավոր բաղադրիչը** պարունակում է ևս 20.3%: Միասին միայն այս երկու առանցքները (PC1 & PC2) նկարագրում են տվյալների բազայի ինֆորմացիայի ավելի քան **61.3%-ը**:



Մոդելի չափականության նվազեցման (Dimensionality Reduction) նպատակով իրականացվել է Scree Plot-ի վերլուծություն: Գրաֆիկից երևում է, որ առաջին երեք գլխավոր բաղադրիչները (PC1, PC2, PC3) համատեղ պահպանում են սկզբնական տվյալների տեղեկատվության ուղիղ 80.96%-ը: Հիմնվելով վիճակագրական 80%-անոց սեմի & Elbow մեթոդի վրա՝ 5 փոփոխականների փոխարեն կարող ենք կիրառել առաջին 3 գլխավոր բաղադրիչները: Սա թույլ է տալիս էապես պարզեցնել մոդելը և խուսափել overfitting-ից կորցնելով տեղեկատվության ընդամենը 19%-ը: **Correlation circle-ը** ցույց է տալիս, թե սկզբնական որ փոփոխականները որ առանցքի հետ են կապված: **Temperature (C) & Humidity**՝ այս երկու վեկտորները PC1 (հորիզոնական) առանցքի վրա ուղղված են ճիշտ հակառակ ուղղություններով (մեկը դեպի -1, մյուսը՝ +1): Սա կրկին հաստատում է ձեր Pairplot-ի արդյունքը՝ ջերմաստիճանը և խոնավությունը ունեն խիստ հակադարձ կապ: **Pressure (millibars)**՝ այս վեկտորը ուղղված է գրեթե ուղղահայաց վերև՝ երկայնքով համընկնելով PC2 առանցքի հետ: Քանի որ այն մոտ 90 աստիճանի անկյուն է կազմում ջերմաստիճանի և խոնավության վեկտորների հետ, դա վկայում է այն մասին, որ մթնոլորտային ճնշումը կախված չէ այդ երկուսից: **Wind Speed & Visibility**՝ այս վեկտորները համեմատաբար կարճ են և ունեն անկյունային դիրքեր, ինչը նշանակում է, որ դրանց վարքագիծը ավելի բարդ է և ամբողջությամբ չի բացատրվում միայն այս երկու առանցքներով (դրանք հավանաբար ավելի լավ են արտահայտված PC3 կամ PC4 առանցքներում):



Data point map/Projection of Data onto PC1 and PC2՝ տվյալների գերակշիռ մասը հավաքված է PC2 առանցքի զրոյական գծի շուրջ (վերևի հատվածում) և հավասարաչափ սփռված է PC1 (ջերմաստիճան/խոնավություն) առանցքով: Ներքևի հատվածում (երբ PC2-ը -6-ից ցածր է) մենք տեսնում ենք մոտ 6-7 կետ, որոնք խիստ առանձնացած են հիմնական խմբից: Քանի որ մենք արդեն գիտենք, որ PC2-ը հիմնականում պատասխանատու է «ճնշման» (Pressure) համար, կարող ենք ենթադրել, որ այս առանձնացած կետերը ներկայացնում են այն եզակի օրերը, երբ եղել է ոչ նորմալ ցածր կամ տարբերվող մթնոլորտային ճնշում:

6. Variance Inflation Factor

Բազմակի գծային ռեգրեսիայի (OLS) արդյունքների ամփոփման մեջ արձանագրվել է բարձր Condition Number ($1.30 \cdot 10^4$), ինչը, համաձայն մոդելի ավտոմատ նախազգուշացման (Note [2]), կարող է վկայել հնարավոր ուժեղ մոլտիկոլինարության կամ թվային այլ խնդիրների մասին: Այս հիպոթեզը ստուգելու և գործոնների միջև գծային կախվածությունը բացառելու նպատակով իրականացվել է Դիսպերսիայի Ինֆլացիայի Գործոնի (VIF) հաշվարկ: Վերլուծությունից միտումնավոր դուրս է թողվել կախյալ փոփոխականը (Apparent Temperature), որպեսզի գնահատվի բացառապես անկախ բաղադրիչների ներքին փոխկապակցվածությունը: Ստացված արդյունքները փաստում են, որ բոլոր 5 անկախ փոփոխականների VIF արժեքները գտնվում են 1.02-ից 1.89 միջակայքում, ինչը զգալիորեն ցածր է վիճակագրական կրիտիկական շեմ համարվող 5.0-ից: Սա միանշանակ ապացուցում է,

	Feature	VIF
0	const	139.40
1	Temperature (C)	1.85
2	Humidity	1.89
3	Wind Speed (km/h)	1.14
4	Visibility (km)	1.28
5	Pressure (millibars)	1.02

որ մոդելում մոլտիկոլինետարության խնդիր գոյություն չունի:

Եզրակացություն

Կառուցված բազմաչափ գծային ռեգրեսիայի (OLS) մոդելում ընտրված հինգ անկախ օդերևութաբանական գործոնները 99.1%-ով ամբողջությամբ բացատրում են մարմնի զգացվող ջերմաստիճանի (Apparent Temperature) տատանումները: Ջերմաստիճանի և խոնավության գործոնների միջև առկա է ընդգծված հակադարձ կապ, ինչը հաջողությամբ հիմնավորվել է նաև երկրաչափական վերլուծության փուլում: Գլխավոր բաղադրիչների վերլուծության (PCA) և Scree Plot գրաֆիկի միջոցով հիմնավորվել է տվյալների չափականության նվազեցման (Dimensionality Reduction) հնարավորությունը: Առաջին երեք գլխավոր բաղադրիչները (PC1, PC2, PC3) համատեղ պահպանում են սկզբնական տվյալների տեղեկատվության 80.66%-ը: Սա թույլ է տալիս հետագա մոդելավորման փուլերում սկզբնական 5 փոփոխականների փոխարեն կիրառել 3 բաղադրիչները՝ Էապես պարզեցնելով տվյալների կառուցվածքը և խուսափելով գերմարզման (overfitting) էֆեկտից: Որպես հետազոտության ընդլայնում և գծային մոդելների այլընտրանք, աշխատանքի կից **Չափվածում** ներառվել և ծրագրային մակարդակով իրականացվել են մեքենայական ուսուցման երկու առանցքային ալգորիթմներ՝

1. K-Մերձավոր Չարևանների մեթոդը (KNN - K-Nearest Neighbors)

2. Աջակցող Վեկտորների Մեքենան (SVM - Support Vector Machines)

Նպատակը և կիրառությունը. Այս ալգորիթմները նախատեսված են տվյալների բազայում առկա ավելի բարդ, ոչ գծային օրինաչափությունների և փոխադրեցությունների խորքային ուսումնասիրության համար: Դրանք թույլ են տալիս իրականացնել եղանակային պայմանների դասակարգում (Classification), անոմալիաների նույնականացում և զգացվող ջերմաստիճանի ոչ գծային կանխատեսումներ: Հավելվածում ներկայացված գործիքակազմը հիմք է հանդիսանում մոդելի ճշգրտության հետագա օպտիմալացման և մեքենայական ուսուցման տարբեր ճարտարապետությունների էֆեկտիվության համեմատական գնահատման համար:

Հավելված

1. Տվյալների Չույգային Վերլուծություն (Pairplot Analysis)

Այս վիզուալիզացիան թույլ է տալիս գնահատել եղանակային գործոնների միջև առկա գծային և ոչ գծային կախվածությունները: Անկյունագծի վրա պատկերված են յուրաքանչյուր փոփոխականի բաշխումները (density plots), իսկ մնացած մասերում՝ դրանց համատեղ բաշխումները (scatter plots):

Հիմնական եզրակացություններ.

- Ջերմաստիճանի և Մարմնի Ջերմաստիճանի կապը (Temperature vs. Apparent Temperature) - Գրաֆիկի ամենահետաքրքիր մասը վերջին տողի առաջին սյունակն է և առաջին տողի վերջին սյունակը: Այստեղ տեսնում ենք զրեթե կատարյալ դրական գծային կապ: Սա նշանակում է, որ օդի ջերմաստիճանը մարմնի ջերմաստիճանի ընկալման հիմնական որոշիչ գործոնն է:
- Խոնավության ազդեցությունը (Humidity) - Դիտարկելով Humidity սյունակը՝ տեսնում ենք, որ ջերմաստիճանի բարձրացման հետ հարաբերական խոնավությունը նվազում է: Սա բնորոշ է եղանակային տվյալներին. տաք օրերը հաճախ ավելի չոր են, իսկ ցուրտ օրերը՝ ավելի խոնավ:
- Քամու արագություն և Տեսանելիություն (Wind Speed & Visibility) - Wind Speed-ը ցույց է տալիս բավականին ցրված բաշխում, ինչը հուշում է, որ քամին կարող է փոփոխվել՝ անկախ ջերմաստիճանից: Visibility-ի բաշխումը երկգագաթ (bimodal) է՝ ունի երկու պիկ, ինչը նշանակում է, որ տվյալներում գերակշռում են կամ շատ լավ տեսանելիությամբ օրեր, կամ էլ մառախլապատ/ցածր տեսանելիությամբ օրեր:
- Մթնոլորտային ճնշում (Pressure) - Ճնշման գրաֆիկը (հինգերորդ տող/սյունակ) ցույց է տալիս, որ տվյալների մեծ մասը կենտրոնացած է մեկ նեղ միջակայքում (մոտ 1000 millibars), ինչը հուշում է, որ ընտրված ընտրանքում ճնշման կտրուկ տատանումներ շատ քիչ են եղել:

2. Shapiro-Wilk թեստ

Shapiro-Wilk թեստը վիճակագրական ամենաուժեղ գործիքներից է՝ ստուգելու համար, թե արդյոք տվյալները ունեն նորմալ բաշխում:

1. Ինչպե՞ս է հաշվարկվում (Մաթեմատիկական հիմքը)

Թեստի հիմքում ընկած է W-վիճակագրությունը: Այն ցույց է տալիս, թե որքանով են տվյալները մոտիկ «նորմալ բաշխման» տեսական գծին:

Հաշվարկման քայլերը.

Տվյալների դասավորում. Տվյալները դասավորվում են աճման կարգով՝ $x(1), x(2), \dots, x(n)$:

Գործակիցների ընտրություն. Օգտագործվում են հատուկ գործակիցներ՝ a_i , որոնք կախված են դիտարկումների թվից (n) և նորմալ բաշխման ակնկալվող արժեքներից:

W բանաձևը. Հաշվարկվում է հետևյալ բանաձևով.

$$W = \frac{(\sum_{i=1}^n a_i x_{(i)})^2}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

Համարիչը (numerator) ցույց է տալիս, թե որքանով են տվյալները «գծային»՝ նորմալ բաշխման ենթադրությանը համապատասխան:

Հայտարարը (denominator) տվյալների ընդհանուր վարիացիան է (տատանումը):

Եթե W-ն մոտ է 1-ի, տվյալները շատ մոտ են նորմալ բաշխմանը:

Եթե W-ն փոքր է, ապա տվյալները շեղվում են նորմալ բաշխումից:

Եթե $p < 0.05$, մենք մերժում ենք «նորմալ բաշխված լինելու» վարկածը:

3. Մեքենայական Ուսուցման Մոդելների Համեմատություն (ML Models)

Մարմնի ջերմաստիճանը կանխատեսելու համար, բացի OLS-ից, կիրառվել են երկու առաջադեմ ալգորիթմներ՝ K-Nearest Neighbors (KNN) և Support Vector Machine (SVM): Մոդելները գնահատվել են անկախ թեստային տվյալների (X_{test} , y_{test}) վրա:

1. KNN (K-Nearest Neighbors) — K-Մոտ Հարևանների Մեթոդ

KNN-ը տվյալների գիտության մեջ ամենապարզ և բնական ալգորիթմներից է: Նրա հիմքում ընկած է նմանության գաղափարը: Երբ մոդելին տրվում է նոր տվյալ (օրինակ՝ այսօրվա ջերմաստիճանը, խոնավությունը և քամու արագությունը), ալգորիթմը թերթում է իր ողջ արխիվը և փնտրում է դրան իրենց բնութագրերով ամենամոտ գտնվող K հատ օրերը (հարևաններին): Ռեգրեսիայի դեպքում մոդելը վերցնում է այդ K հարևան օրերի զգացվող ջերմաստիճանները, հաշվում է դրանց միջին թվաբանականը և հայտարարում որպես կանխատեսում: Պարամետր (K). Եթե K-ն չափից փոքր է, մոդելը դառնում է չափազանց զգայուն աղմուկի նկատմամբ, իսկ եթե չափից մեծ է՝ կորցնում է ճշգրտությունը:

2. SVM (Support Vector Machines)

SVM-ը շատ ավելի հզոր և մաթեմատիկորեն բարդ ալգորիթմ է: Նրա նպատակն է տվյալների խմբերի միջև իդեալական սահմանագիծ գտնելը: Դիտարկենք երկու խմբի տվյալներ (օրինակ՝ «Շոգ օրեր» և «Ցուրտ օրեր»): SVM-ը փորձում է դրանց միջև գծել մի այնպիսի սահմանային գիծ (կամ բազմաչափ հարթություն՝ Hyperplane), որը երկու կողմի տվյալներից էլ կգտնվի առավելագույնս հեռու: Այդ ազատ տարածությունը կոչվում է Margin (Լուսանցք): Support Vectors-ը այն ամենաեզրային կետերն են (օրերը), որոնք կանգնած են սահմանագծին ամենամոտը: Kernel Trick. Սա SVM-ի ամենաուժեղ կողմն է: Եթե տվյալները խառնված են և հնարավոր չէ ուղիղ գծով բաժանել, SVM-ը մաթեմատիկորեն տանում է տվյալները ավելի բարձր չափականության մեջ (օրինակ՝ 2D հարթությունից տեղափոխում է 3D տարածություն): Այնտեղ տվյալները տարանջատվում են, և մոդելը հեշտությամբ հարթ պատով բաժանում է դրանք:

Մոդելների Համեմատություն

Ահա ստացված արդյունքների պատկերը.

- **Գծային Ռեգրեսիա (OLS):** $R^2 = 0.9910$
- **KNN Regressor:** $R^2 = 0.9555$
- **SVM Regressor (SVR):** $R^2 = 0.9531$

Թեև KNN և SVM մոդելները ցուցաբերել են շատ բարձր ճշգրտություն (տվյալների տատանումների ավելի քան **95%**-ը բացատրվում է), դրանք զիջում են ավանդական գծային ռեգրեսիային (OLS), որն ունի գրեթե իդեալական **99.1%** ճշգրտություն:

Ինչո՞ւ է գծային մոդելն ավելի լավ աշխատել.

Օդերևութաբանական տվյալներում իրական ջերմաստիճանի և մարմնի զգացվող ջերմաստիճանի (Apparent Temperature) միջև կապը բնության մեջ մեծամասամբ **գծային է**: Քանի որ կապն ուղիղ է, OLS մոդելը հեշտությամբ և անթերի որսում է այն: Իսկ KNN-ն ու SVM-ը փնտրում են ավելի բարդ, ոչ գծային կորեր ու օրինաչափություններ, ինչն այս տվյալների դեպքում հանգեցրել է չնչին smoothing-ի և ճշգրտության անկման:

Եզրակացություն

Մեքենայական ուսուցման ալգորիթմների կիրառումը փաստեց, որ ինչպես **KNN** ($R^2 = 0.9555$), այնպես էլ **SVM** ($R^2 = 0.9531$) մոդելներն օժտված են կանխատեսման բարձր որակով: Այնուամենայնիվ, համեմատական վերլուծությունը ցույց է տալիս, որ բազմաչափ գծային ռեգրեսիան (OLS) պահպանում է լավագույն արդյունավետությունը ($R^2 = 0.991$): Սա հիմնավորում է այն փաստը, որ օդերևութաբանական հիմնական գործոնների և մարմնի զգացվող ջերմաստիճանի միջև փոխկապակցվածությունը կրում է հիմնականում գծային բնույթ, և լրացուցիչ ոչ գծային ալգորիթմների ներմուծումը չի հանգեցնում մոդելի որակական բարելավման: ML մոդելների արդյունքները ներառված են հավելվածում՝ որպես այլընտրանքային հուսալի գործիքակազմ: